

Laporan Praktikum Minggu Ke-5 Kontrol Cerdas

Minggu ke-5

Nama : Rafly Yudhsitira Ananta
NIM : 224308067
Kelas : TKA 7C
Akun Github (Tautan) : <https://github.com/RaflyYudhistiraAnanta>

1. Judul Percobaan

Reinforcement Learning untuk Kontrol Kompleks

2. Tujuan Percobaan

Tujuan dari percobaan pada praktikum kali ini, sebagai berikut:

1. Mahasiswa dapat memahami konsep dasar Reinforcement Learning dalam kontrol kompleks.
2. Mahasiswa dapat Mengimplementasikan DEEP Q-Network (DQN) untuk kontrol otomatis.
3. Mahasiswa dapat menganalisis performa DRL dibandingkan dengan metode kontrol konvensional.

3. Landasan Teori

Reinforcement Learning (RL) adalah cabang kecerdasan buatan yang memungkinkan mesin atau robot secara otomatis menentukan tindakan terbaik dalam situasi tertentu untuk memaksimalkan kinerjanya. Metode ini bekerja dengan cara agen belajar dari umpan balik lingkungan, sehingga dapat beradaptasi dan meningkatkan performa seiring waktu. Dengan kemampuan adaptasi ini, mesin atau agen diharapkan dapat mencapai kinerja yang lebih optimal dan efisien dalam berbagai kondisi (Cholissodin & Setyawan, n.d.).

Deep Q-Network (DQN) adalah algoritma reinforcement learning yang menggabungkan Q-learning dengan deep neural network untuk mengaproksimasi fungsi nilai Q dalam lingkungan dengan ruang keadaan dan tindakan yang besar dan kompleks. Berbeda dengan Q-learning tradisional yang menyimpan nilai Q dalam tabel (Q-table) yang sulit diterapkan pada masalah

berskala besar, DQN menggunakan deep neural network sebagai fungsi aproksimator untuk memprediksi nilai Q berdasarkan keadaan dan tindakan tertentu. Neural network ini menerima input berupa representasi keadaan dan menghasilkan nilai Q untuk setiap tindakan yang mungkin. DQN juga menerapkan teknik Experience Replay, yaitu menyimpan dan mengambil ulang pengalaman secara acak untuk meningkatkan stabilitas pembelajaran (Putra et al., 2024),

4. Diskusi dan Assignment

DISKUSI

1. Apa kelebihan dan kelemahan DQN dibandingkan metode Q-Learning klasik?

Kelebihan utama dari Deep Q-Network (DQN) dibandingkan metode Q-Learning klasik terletak pada kemampuannya menangani ruang state yang besar dan kontinu. Jika Q-Learning tradisional hanya dapat bekerja dengan jumlah state yang terbatas karena menggunakan tabel Q-Value (Q-table), maka DQN menggunakan jaringan saraf tiruan (Neural Network) untuk memperkirakan nilai Q sehingga mampu memproses input yang kompleks seperti data sensor, citra kamera, atau kondisi lingkungan yang berubah-ubah. Selain itu, DQN lebih efisien dalam penggunaan memori dan mampu beradaptasi terhadap lingkungan dinamis melalui mekanisme *experience replay* dan *epsilon-greedy strategy*. Teknik ini membuat pembelajaran menjadi lebih stabil dan efisien. Namun, DQN juga memiliki beberapa kelemahan, di antaranya membutuhkan daya komputasi yang besar karena proses pelatihannya melibatkan banyak literasi jaringan saraf, serta membutuhkan waktu dan data yang jauh lebih banyak dibandingkan Q-Learning klasik. Selain itu, kestabilan pembelajaran DQN sangat bergantung pada pemilihan parameter seperti *learning rate*, *epsilon decay*, dan arsitektur jaringan yang digunakan. Jika tidak diatur dengan baik, DQN dapat mengalami pelatihan yang tidak stabil.

2. Bagaimana cara mengadaptasi DQN untuk kontrol sistem dinamis seperti drone atau robot industri?



Untuk mengadaptasi DQN dalam kontrol sistem dinamis seperti drone atau robot industri, diperlukan beberapa penyesuaian baik dari sisi representasi state, algoritma, maupun lingkungan pembelajaran. Pertama, representasi state harus mencakup parameter penting seperti posisi, kecepatan, sudut kemiringan, maupun data sensor yang relevan, dan semua data tersebut perlu dinormalisasi agar jaringan saraf dapat belajar secara optimal. Kedua, karena sistem dinamis umumnya bersifat kontinu, algoritma DQN perlu dimodifikasi menggunakan varian seperti *Deep Deterministic Policy Gradient (DDPG)* untuk aksi kontinu atau *Double DQN* dan *Dueling DQN* untuk meningkatkan stabilitas dan akurasi prediksi Q-value. Setelah model menunjukkan performa stabil di simulasi, dilakukan *fine-tuning* pada data nyata agar sistem mampu beradaptasi terhadap gangguan lingkungan dan noise sensor. Dengan pendekatan ini, DQN dapat digunakan secara efektif untuk mengontrol sistem kompleks seperti drone dan robot industri dengan hasil yang adaptif, efisien, dan presisi tinggi.


Assignment

Untuk menerapkan DQN pada pengendalian sistem dinamis seperti drone atau robot industri, diperlukan modifikasi pada representasi state, algoritma, dan lingkungan pelatihan. Pertama, state harus mencakup variabel esensial seperti posisi, kecepatan, sudut kemiringan, serta data sensor relevan, dengan normalisasi penuh agar jaringan saraf memproses pembelajaran secara efisien. Kedua, mengingat karakter kontinu sistem tersebut, adaptasikan DQN melalui varian seperti *Deep Deterministic Policy Gradient (DDPG)* untuk aksi kontinu, atau *Double DQN* dan *Dueling DQN* guna meningkatkan kestabilan serta akurasi estimasi Q-value. Ketiga, sesuaikan fungsi reward dengan sasaran kontrol, seperti memberikan poin tinggi pada drone untuk menjaga posisi stabil dengan konsumsi energi rendah. Selain itu, lakukan pelatihan di simulator autentik seperti Gazebo, AirSim, atau MuJoCo untuk mencegah risiko kerusakan hardware pada uji nyata, diikuti fine-tuning menggunakan data aktual agar sistem adaptif terhadap interferensi lingkungan dan noise sensor. Strategi ini memungkinkan DQN diterapkan secara optimal pada sistem rumit, menghasilkan performa adaptif, efisien, dan akurat tinggi.

5. Output Hasil

Untuk mengadaptasi DQN dalam pengendalian sistem dinamis seperti drone atau robot industri, diperlukan penyesuaian pada representasi state, algoritma, serta lingkungan pelatihan. Pertama, state harus meliputi elemen kunci seperti posisi, kecepatan, sudut kemiringan, dan data sensor terkait, dengan normalisasi lengkap agar jaringan saraf belajar secara efisien. Kedua, karena sifat kontinu sistem ini, modifikasi DQN melalui varian seperti Deep Deterministic Policy Gradient (DDPG) untuk aksi kontinu, atau Double DQN dan Dueling DQN untuk memperkuat kestabilan serta presisi estimasi Q-value. Ketiga, rancang fungsi reward sesuai tujuan kontrol, misalnya reward tinggi untuk drone yang mempertahankan posisi stabil dengan energi minimal. Selain itu, jalankan pelatihan di simulator realistis seperti Gazebo, AirSim, atau MuJoCo guna menghindari kerusakan hardware pada pengujian nyata, diikuti fine-tuning dengan data real untuk adaptasi terhadap gangguan lingkungan dan noise sensor. Pendekatan ini memungkinkan DQN diterapkan secara efektif pada sistem kompleks, mencapai performa adaptif, efisien, dan akurat tinggi.

NO.	Penjelasan	Dokumentasi
1.	Sistem menggunakan MediaPipe untuk mengenali dan memberi label “Right Hand” pada tangan kanan, serta menampilkan titik-titik sendi dan garis penghubung sebagai hasil pendeteksian posisi jari secara real-time melalui kamera.	
2.	Sistem menggunakan MediaPipe untuk mengenali dan memberi label “left Hand” pada tangan kanan, serta menampilkan titik-titik sendi dan garis penghubung sebagai hasil pendeteksian posisi jari secara real-time melalui kamera.	

3.	menunjukkan hasil program deteksi dua tangan (kiri dan kanan) menggunakan MediaPipe di Python. Sistem berhasil mengenali kedua tangan secara real-time, memberi label “Left Hand” dan “Right Hand”, serta menampilkan titik-titik sendi dan garis penghubung pada masing-masing tangan sebagai hasil identifikasi posisi jari.	
----	--	--

6. Kesimpulan

Berdasarkan hasil eksperimen, penerapan MediaPipe Hands berhasil mendeteksi dan melacak posisi tangan secara real-time dengan akurasi tinggi. Sistem mengidentifikasi 21 landmark sendi tangan, dari pergelangan hingga ujung jari, dan memvisualisasikannya melalui titik merah yang dihubungkan garis hijau, membentuk struktur tangan lengkap. Integrasi OpenCV dan MediaPipe berjalan stabil, meskipun ada perubahan posisi tangan atau variasi pencahayaan lingkungan. Output deteksi ini berpotensi besar sebagai input state untuk Deep Reinforcement Learning (DRL), khususnya Deep Q-Network (DQN). Data posisi sendi dapat menjadi representasi visual bagi agen DRL untuk belajar aksi seperti menggerakkan lengan robot, mengontrol arah kendaraan otonom, atau menjalankan perintah gestur manusia. Eksperimen ini tidak hanya membuktikan kemampuan deteksi tangan, tetapi juga membuka peluang integrasi computer vision dengan reinforcement learning untuk kontrol otomatis berbasis isyarat. Implementasi ini memiliki keunggulan utama, seperti non-invasif hanya dengan kamera sebagai sensor utama, serta menyediakan representasi visual kaya tanpa hardware tambahan. Hasil ini menjadi fondasi kuat untuk pengembangan sistem kontrol yang lebih cerdas, adaptif, dan interaktif. Secara keseluruhan, penggabungan deteksi tangan berbasis

visi dengan DRL merupakan langkah krusial menuju sistem kontrol kompleks masa depan yang mampu belajar, beradaptasi, dan berinteraksi alami dengan manusia di robotika, industri, serta kendaraan otonom.

7. Daftar Pustaka

- Akbari, M. F. R., Rahayudi, B., & Muflikhah, L. (n.d.). *Implementasi Deep Learning menggunakan Algoritma EfficientDet untuk Sistem Deteksi Kelayakan Penerima Bantuan Langsung Tunai berdasarkan Citra Rumah di Wilayah Kabupaten Kediri.*
- Cholissodin, I., & Setyawan, G. E. (n.d.). *Pengembangan Reinforcement Learning (RL) Single-Agent Menggunakan Improve Q-Learning.*